

Parametrización y segmentación de las capas de la retina mediante técnicas de aprendizaje profundo

Septiembre 2021, ETSIAE, UPM


Christian Mariscal Calvo

Índice

- Justificación del estudio
- Metodología y desarrollo
 - Conceptos preliminares
 - Preparación de datos
 - Métricas
 - Función de entrenamiento y test
- Resultados
- Conclusiones
- Pasos futuros
- Bibliografía

Justificación del estudio

- Al menos 2200 millones de personas con deficiencia visual en el mundo, 1000 de ellas podrían evitarse (Fuente: OMS)
- Estudios previos con buenos resultados: IoU: 90,41% (Qiaoliang Li et al., *Deep Retina: Layer segmentation of retina in OCT images using deep learning*)




(Figura 1. Fuente: OMS)

Metodología y desarrollo

Conceptos preliminares

Estructura de la retina y OCT



Figuras 2,3,4: Conceptos preliminares

Metodología y desarrollo

Preparación de datos

- One-hot encoding.
- Tratamiento de la superposición
- Resize

Metodología y desarrollo

Preparación de datos

One-hot encoding

- En datos sin jerarquía, permite transformarlos (numéricos o categóricos) en vectores de 0 y 1 manteniéndolos sin jerarquía.

LABEL VALUE	ONE-HOT VALUE
0	[1,0,0,0,0]
1	[0,1,0,0,0]
2	[0,0,1,0,0]
3	[0,0,0,1,0]
4	[0,0,0,0,1]

Figura 5: Codificación One-Hot

Metodología y desarrollo

Preparación de datos

Tratamiento de la superposición

- Superposición al unir las máscaras de cada capa en una única máscara.
- Obtención de píxeles de valor -1 al restar el epitelio pigmentario
- Solución: Eliminar la línea fina blanca.



Figura 6: Evidencia de superposición en Dataset

Metodología y desarrollo

Preparación de datos

Resize

- No todas las imágenes del Dataset tenían el mismo tamaño.
- Necesidad de tener mismos tamaños para la entrada en modelo.
- Resize → pérdida de calidad




Figura 7: Imagen tras One-Hot




Figura 8: Imagen tras One-Hot + resize

Metodología y desarrollo

Preparación de datos

Resize

- Solución aplicada:




Figura 9: Solución a la pérdida de calidad por resize

Metodología y desarrollo

Métricas empleadas

- Se exponen dos de las métricas empleadas:
 - Loss o función de pérdida
 - Matriz de confusión

Metodología y desarrollo

Métricas empleadas

Loss

- Empleo de *binary cross entropy with logits loss* como función de pérdida ([A survey of loss functions for semantic segmentation](#)).
- *Binary cross entropy with logits loss* combina binary cross entropy y la función de activación sigmoide.

$$l = \text{mean}\{l_1, l_2 \dots l_n\}, \quad l_n = -w_n [y_n * \log \sigma(x_n) + (1 - y_n) * \log(1 - \sigma(x_n))]$$

Figura 10: Ecuación de *BinaryCrossEntropyWithLogitsLoss*

Metodología y desarrollo

Métricas empleadas

Confusion Matrix

- Es la métrica más explicativa.

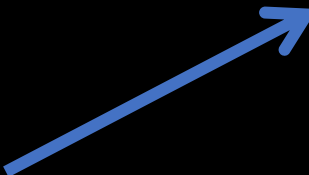
Classes	0	1	2	3	4
0	1.3278e+08	9.3584e+04	1.4e+01	1e+0	9.2013e+04
1	7.3148e+04	2.3533e+06	7.2476e+04	7.5e+01	0
2	6e+0	6.9057e+04	1.8458e+06	5.7779e+04	1.735e+03
3	4.1e+01	1.1e+02	1.3499e+05	6.9688e+05	8.8389e+04
4	1.0001e+05	0	2.4500e+02	7.1034e+04	1.8839e+07

Figura 11: Matriz de confusión obtenida en entrenamiento de segmentación multicapa

Metodología y desarrollo

Función de entrenamiento y test

- Primer paso: Entrada de hiperparámetros a través de formulario.
- Segundo paso: Actualización de 'weights'.
- Para ello:
 1. Cálculo de *loss*
 2. Propagar los gradientes (*loss.backward*)
 3. Actualizar los pesos empleando optimizador (*Adam optimizer*)


$$\frac{\partial loss}{\partial w} = \frac{\partial loss}{\partial y} \times \frac{\partial y}{\partial w}$$

$$New\ weight = Old\ weight - learning\ rate \times \frac{\partial(loss)}{\partial (old\ weight)}$$

Figura 12: Actualización de pesos de Gradient Descent optimizer.

Resultados

- Segmentación de la retina completa

Model:resnet_101, BatchSize:6, Learning rate:0.1, Epochs:50, Early Stopping:10, Train Dataset Length:800, Data Augmentation:False	
Test Loss	0.0097
Test IoU	0.9868
Test Accuracy	0.8740

Figura 13: Resultados obtenidos en segmentación de la retina completa con resnet_101

Resultados

- Segmentación de la retina completa




Figura 14: Resultados obtenidos en la segmentación total de la retina, empleando UNet con datos de la tabla de la anterior diapositiva.

Resultados

- Segmentación multicapa

Model: resnet_101, BatchSize:3, Learning rate:0.001, Epochs:15, Early Stopping:5, Train Dataset Length:600, Data Augmentation:False	
Test Loss	0.0067
Test IoU	0.8320
Test Accuracy	0.9949

Figura 15: Resultados obtenidos en segmentación multicapa con resnet_101

Resultados




Figura 16: Resultados obtenidos en segmentación multicapa con resnet_101 con datos de la tabla de la anterior diapositiva.

Resultados

Obtención de espesores, gráfica 3D.

- 1. Para obtener los espesores directamente de la máquina: Se extrae la información binaria de los archivos .vol originales.
- 2. Para obtenerlos a partir de las predicciones: A partir de la segmentación binaria.

Resultados

Obtención de espesores, gráfica 3D.


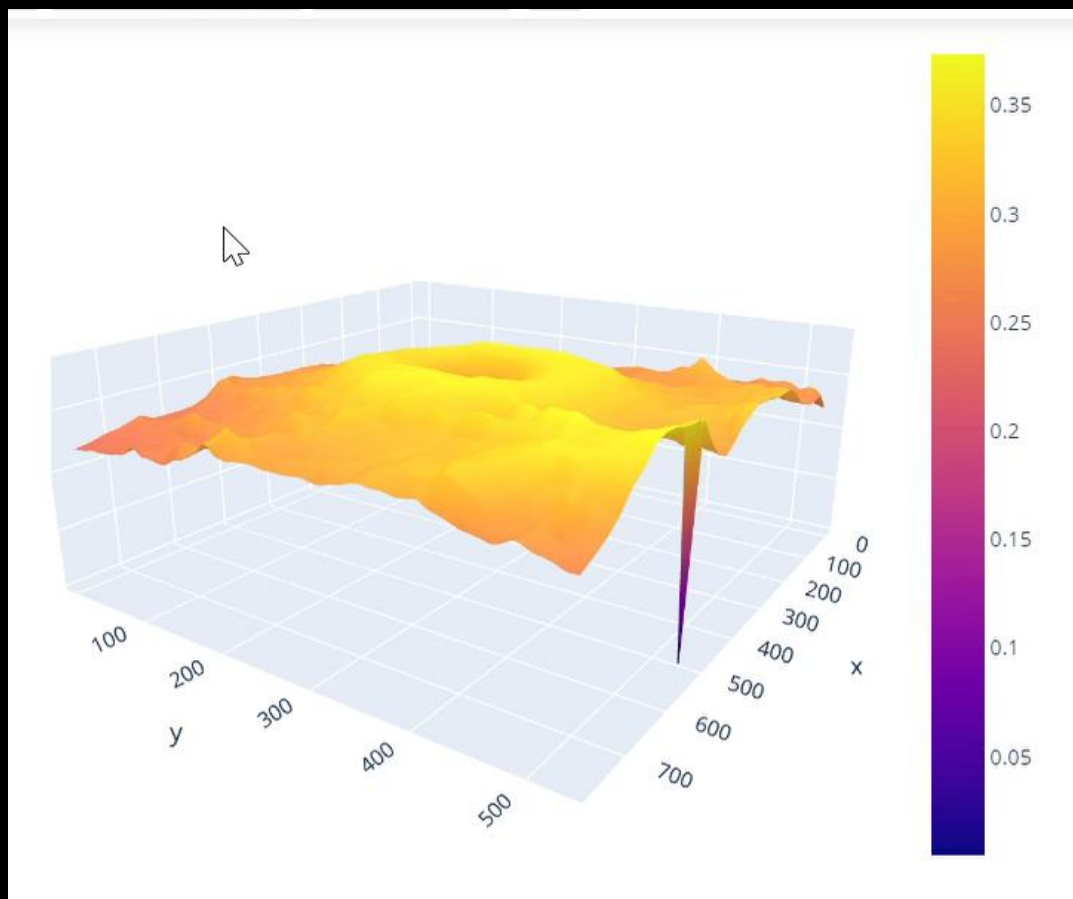
- Problemas con imágenes que no ocupan todo el ancho.
- Necesidad de interpolación y eliminación de bordes.



Figura 17: Imagen OCT con problemas para obtener espesores

Resultados Gráfica 3D

Valores de espesor de retina: 0.20-0.35 mm



Animaciones 1 y 2. Espesor de retina paciente sano. Izquierda: Spectralis. Derecha: Segmentación binaria

Conclusiones

- Resultados precisos, según métricas y visualizaciones.
- Similares resultados para todas las arquitecturas.
- Mejoras con learning rate más pequeños.
- UNet la más eficiente.
- Tamaño del Dataset adecuado.

Pasos futuros

- Corrección del Dataset
- Modelo de clasificación
- Necesidad de obtener una GPU potente y de forma continua
- Aplicación completa para su uso profesional
- Análisis estadístico de los datos de pacientes→situación poblacional

Bibliografía

- [1]: Li, Q., Li, S., He, Z., Guan, H., Chen, R., Xu, Y., Wang, T., Qi, S., Mei, J., & Wang, W. (2020, December 9). DeepRetina: Layer segmentation of retina in OCT images using deep learning. Translational vision science & technology. Retrieved September 14, 2021.
- [2] Dan P. Popescu et al. (2011, August), Optical coherence tomography: fundamental principles, instrumental designs and biomedical applications (nih.gov).
- [3]: Long, J., Shelhamer, E., & Darrell, T. (2015, March 8). Fully convolutional networks for semantic segmentation. Retrieved September 14, 2021.
- [4]: Chen, L.-C., Papandreou, G., Schroff, F., & Adam, H. (2017, December 5), Rethinking atrous convolution for semantic image segmentation. Retrieved September 14, 2021.
- [5]: PyTorch, PyTorch Documentation. Retrieved September 14, 2021.
- [6]: Sensio. Inteligencia Artificial desde cero en castellano. Retrieved September 14, 2021.

¡GRACIAS POR SU ATENCIÓN!
¿Alguna pregunta?